

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E
TECNOLOGIA DA BAHIA - IFBA**

BRENDON SOUSA LIMA

**MÓDULO DE VISÃO COMPUTACIONAL EMBARCADO PARA
ROBÓTICA AUTÔNOMA**

Vitória da Conquista

2025

BRENDON SOUSA LIMA

**MÓDULO DE VISÃO COMPUTACIONAL EMBARCADO PARA
ROBÓTICA AUTÔNOMA: ANÁLISE COMPARATIVA DE
PLATAFORMAS E DESENVOLVIMENTO DE PROTÓTIPO DE BAIXO
CUSTO**

Projeto de Pesquisa apresentado como requisito parcial de avaliação da disciplina Trabalho de Conclusão de Curso I, do curso de Bacharelado em Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia da Bahia – IFBA, sob orientação do Prof. Andrique Figueirêdo Amorim.

Vitória da Conquista

2025

RESUMO

Este trabalho propõe o desenvolvimento de um módulo de visão computacional embarcado de baixo custo para robótica autônoma, utilizando o microcontrolador ESP32-S3 e um sistema óptico catadióptrico (espelho convexo). A pesquisa aborda o desafio de implementar detecção de objetos em tempo real em dispositivos com recursos limitados, comparando a viabilidade técnica entre algoritmos de segmentação por cor no espaço HSV e modelos de Tiny Machine Learning (TinyML). O módulo desenvolvido captura imagens omnidirecionais, processa-as localmente e fornece as coordenadas (x, y) de objetos, especificamente uma bola laranja, para integração com sistemas de controle de robôs. A metodologia adota uma abordagem incremental, iniciando com validação em visão superior estática e evoluindo para visão embarcada com espelho convexo. São avaliadas métricas de desempenho como acurácia, latência, quadros por segundo (FPS) e consumo energético, visando um equilíbrio ideal para aplicações dinâmicas como o futebol de robôs. A contribuição esperada é democratizar o acesso à tecnologia robótica através de uma solução com custo total inferior a R\$ 200,00, mantendo desempenho aceitável para aplicações educacionais e de pesquisa.

Palavras-chave: Visão Computacional Embarcada. ESP32-S3. Óptica Catadióptrica. Segmentação HSV. Robótica Autônoma.

ABSTRACT

This work proposes the development of a low-cost embedded computer vision module for autonomous robotics using the ESP32-S3 microcontroller and a catadioptric optical system (convex mirror). The research addresses the challenge of implementing real-time object detection on resource-constrained devices by comparing the technical viability of Color Segmentation algorithms (HSV color space) against Tiny Machine Learning (TinyML) models. The developed module captures omnidirectional images, processes them locally, and provides object coordinates (x, y), specifically for an orange ball, for integration with robot control systems. The methodology follows an incremental approach, starting with static top-view validation and evolving to embedded vision with a convex mirror. Performance metrics such as accuracy, latency, frames per second (FPS), and energy consumption are evaluated to achieve an optimal balance for dynamic applications like robot soccer. The expected contribution is to democratize access to robotics technology by providing a

solution with a total cost under R\$ 200.00, maintaining acceptable performance for educational and research applications.

Keywords: Embedded Computer Vision. ESP32-S3. Catadioptric Optics. HSV Segmentation. Autonomous Robotics.

Sumário

1. INTRODUÇÃO	5
1.1 Justificativa	5
1.2 Problema	6
1.3 Objetivos	6
1.3.1 Geral	6
1.3.2 Específicos	6
1.4 Metodologia	7
2 CONCEITOS TEÓRICOS / TRABALHOS RELACIONADOS	8
3 CRONOGRAMA	11
4 REFERÊNCIAS	13

1. INTRODUÇÃO

A robótica autônoma móvel tem desempenhado um papel crucial na evolução da indústria 4.0 e na automação de tarefas complexas. Em ambientes dinâmicos e competitivos, como o futebol de robôs (RoboCup), a capacidade de perceber o ambiente, identificar objetos de interesse e tomar decisões em tempo real é um requisito fundamental (KITANO et al., 1997).

Tradicionalmente, a percepção visual em robótica móvel depende de duas abordagens: processamento centralizado (câmeras externas ao campo enviando dados via rádio) ou processamento embarcado em hardware de alto custo (como placas com GPUs dedicadas). Ambas as soluções apresentam barreiras significativas para a massificação da robótica educacional e amadora, seja pelo custo de infraestrutura ou pelo consumo energético elevado.

Nesse cenário, o paradigma do Edge AI e do TinyML (Tiny Machine Learning) surge como uma alternativa promissora, permitindo a execução de algoritmos de visão computacional diretamente em microcontroladores de baixo custo (WARDEN; SITUNAYAKE, 2019). Este projeto propõe o desenvolvimento de um módulo de visão embarcada utilizando o microcontrolador ESP32-S3 e uma câmera OV2640.

O diferencial inovador desta proposta reside na integração de um sistema óptico catadióptrico (uso de espelho convexo), que visa ampliar o campo de visão do robô para 360 graus (omnidirecional) com um único sensor, eliminando partes móveis e mantendo o custo do sistema reduzido.

1.1 Justificativa

A relevância deste trabalho é sustentada por três pilares:

Tecnológica: A validação do ESP32-S3 (custo ~R\$ 60,00) como plataforma de visão computacional desafia os limites do hardware atual. A aplicação de técnicas de TinyML e segmentação de cores (HSV) em dispositivos com memória restrita (SRAM < 512KB) contribui para o estado da arte em sistemas embarcados (LIN et al., 2020).

Econômica e Social: Ao propor uma solução com custo total inferior a R\$ 200,00, o projeto democratiza o acesso a tecnologias avançadas de percepção robótica, permitindo que instituições de ensino com orçamentos limitados participem de competições de robótica de nível superior.

Inovação em Design: A utilização de um espelho convexo (catadióptrico) para obter visão panorâmica em um sistema de baixo custo é uma alternativa criativa aos caros sensores LIDAR ou arranjos de múltiplas câmeras, reduzindo a complexidade mecânica e eletrônica do robô.

1.2 Problema

A implementação de visão computacional em robôs móveis de pequeno porte enfrenta um dilema de trade-off (compromisso) entre desempenho e recursos. Plataformas robustas como NVIDIA Jetson ou Raspberry Pi 4 custam entre R\$ 500,00 e R\$ 2.000,00 e demandam baterias volumosas. Por outro lado, microcontroladores baratos frequentemente carecem de memória para processar imagens.

Além disso, câmeras convencionais possuem campo de visão limitado (aprox. 60°), obrigando o robô a girar constantemente para encontrar a bola, o que reduz sua eficiência em jogo. Diante disso, formula-se a seguinte questão de pesquisa:

Qual a viabilidade técnica e o desempenho de um módulo de visão computacional embarcado de baixo custo (baseado em ESP32-S3 e óptica catadióptrica) para a detecção de objetos em tempo real em robôs móveis autônomos?

1.3 Objetivos

1.3.1 Geral

Desenvolver um protótipo funcional de módulo de visão computacional embarcado utilizando o microcontrolador ESP32-S3 e óptica catadióptrica, capaz de detectar uma bola laranja em tempo real e fornecer suas coordenadas relativas para o controle de navegação de um robô autônomo.

1.3.2 Específicos

Realizar levantamento bibliográfico sobre TinyML, segmentação de imagens em microcontroladores e sistemas de visão omnidirecional.

Implementar e comparar algoritmos de detecção de objetos baseados em cor (Espaço HSV) e Machine Learning (TensorFlow Lite Micro) quanto à latência e acurácia.

Desenvolver o suporte físico para acoplamento da câmera OV2640 e do espelho convexo.

Criar algoritmo de mapeamento para converter a imagem distorcida do espelho em coordenadas cartesianas (X, Y) úteis para o robô.

Validar o sistema em etapas incrementais: visão estática superior e visão embarcada omnidirecional.

1.4 Metodologia

A pesquisa classifica-se como aplicada e experimental, com abordagem quantitativa. O desenvolvimento seguirá um processo incremental para isolar variáveis e garantir a robustez do sistema.

1.4.1 Procedimentos Metodológicos

O projeto será executado em três fases principais:

Fase 1: Configuração e Algoritmo Base (Ambiente Controlado) Inicialmente, será configurado o firmware no ESP32-S3 para captura de imagens em resolução reduzida (QVGA ou QQVGA) para otimizar o FPS (Frames Per Second). Serão implementados filtros de segmentação no espaço de cor HSV (Hue, Saturation, Value), que é mais robusto a variações de luz que o RGB, para isolar a cor laranja da bola.

Fase 2: Validação Incremental Para garantir a confiabilidade dos dados, os testes seguirão uma ordem de complexidade:

Visão Superior (Bird's Eye View): O módulo será testado com a câmera apontada diretamente para baixo (sem espelho), capturando a bola em fundo contrastante. O objetivo é validar o algoritmo de detecção e medir o tempo de resposta (latência) sem a distorção óptica.

Visão Catadióptrica (Com Espelho): A câmera será acoplada ao espelho convexo. O algoritmo será adaptado para identificar o "blob" (mancha) laranja na imagem refletida e calcular seu ângulo e distância relativos ao centro da imagem (posição do robô).

Fase 3: Coleta de Métricas e Otimização Serão realizados experimentos práticos medindo:

Latência (ms): Tempo entre captura e saída da coordenada.

Taxa de Acerto (%): Eficácia da detecção em diferentes distâncias (0.5m a 2.0m).

FPS: Fluidez do processamento de vídeo. O objetivo é encontrar o equilíbrio ideal entre resolução da imagem e velocidade de processamento.

2 CONCEITOS TEÓRICOS / TRABALHOS RELACIONADOS

2.1 Visão Computacional em Dispositivos Embarcados

A Visão Computacional é um campo da ciência da computação que foca na replicação da complexidade do sistema visual humano, permitindo que computadores identifiquem e processem objetos em imagens e vídeos. No contexto de Sistemas Embarcados, como o ESP32-S3, a visão computacional enfrenta desafios únicos devido às severas restrições de hardware.

Diferente de um computador pessoal, um microcontrolador não possui memória RAM abundante para carregar imagens inteiras de alta resolução em matrizes flutuantes, nem Unidades de Processamento Gráfico (GPUs) para paralelizar cálculos (BONARDI et al., 2015). O ESP32-S3, embora poderoso para sua classe, possui cerca de 512KB de SRAM interna. Isso exige que algoritmos de visão sejam otimizados para operar in-stream (processando a imagem conforme ela chega da câmera) ou utilizando resoluções reduzidas (como QVGA - 320x240 pixels) para caber na memória.

Neste projeto, a visão computacional embarcada não visa apenas "ver", mas extrair informações semânticas (posição da bola) em tempo hábil para que o robô reaja, exigindo um ciclo de processamento inferior a 100ms.

2.2 Segmentação e Espaço de Cor HSV

A detecção de objetos baseada em cor é uma das técnicas mais eficientes para sistemas de tempo real. No entanto, o espaço de cor padrão das câmeras digitais, o RGB (Red, Green, Blue), apresenta uma desvantagem significativa para robótica móvel: a correlação entre cor e iluminação. No RGB, uma sombra projetada sobre uma bola laranja altera os valores dos três componentes (R, G e B), dificultando a criação de um filtro robusto.

Para mitigar isso, utiliza-se o espaço de cor HSV (Hue, Saturation, Value):

Hue (Matiz): Representa a "cor pura" (ex: vermelho, laranja, azul) em um ângulo de 0° a 360° (Figura 1). É a componente mais importante, pois tende a permanecer constante mesmo sob variações de luz.

Saturation (Saturação): Indica a intensidade ou pureza da cor.

Value (Valor): Representa o brilho da cor.




Figura 1 – Representação do Espaço de Cor HSV (Hue, Saturation, Value).

Ao converter a imagem para HSV, o algoritmo pode aplicar um filtro (threshold) focado apenas no canal Hue correspondente ao laranja (geralmente entre 10° e 25°), ignorando variações no canal Value causadas por sombras ou luzes fortes. Isso torna a detecção computacionalmente leve — ideal para o ESP32 — e robusta para o ambiente dinâmico de um campo de futebol de robôs (MÜHLENBROCK et al., 2018).

2.2 TinyML: Machine Learning na Borda

Quando a segmentação por cor não é suficiente (por exemplo, distinguir uma bola laranja de uma camisa laranja), recorre-se ao Machine Learning. O TinyML viabiliza a execução de redes neurais profundas em microcontroladores através de técnicas como a quantização.

A quantização converte os parâmetros do modelo de ponto flutuante (32 bits) para inteiros (8 bits). Segundo Warden e Situnayake (2019), isso reduz o tamanho do modelo em até 4 vezes e aumenta a velocidade de inferência, permitindo que redes como MobileNet rodem no ESP32-S3, embora com um custo computacional maior que a segmentação HSV simples.

2.3 Sistemas de Visão Omnidirecional (Catadióptricos)

Sistemas catadióptricos combinam elementos refrativos (lentes) e reflexivos (espelhos). Em robótica móvel, o uso de um espelho convexo (Figura 2) alinhado ao eixo óptico da câmera permite capturar o cenário em 360 graus em uma única imagem.




Figura 2 – Esquema de um Sistema de Visão Catadióptrico com Espelho Convexo.

Embora a imagem resultante sofra distorções radiais severas (objetos no centro aparecem maiores e mais distorcidos), ela contém informações de todo o entorno do robô. Isso elimina a necessidade de mecanismos servos para girar a câmera ("pescoço" do robô) ou arranjos caros de múltiplas câmeras. O desafio teórico reside no "desdobramento" matemático dessa imagem para obter coordenadas polares (ângulo e distância) úteis para a navegação do robô.

Entregar trabalho	o										X	X	
Defesa monografia	da												X

4 REFERÊNCIAS

BANBURY, C. R. et al. MicroNets: Neural Network Architectures for Deploying TinyML Applications on Commodity Microcontrollers. In: **Proceedings of Machine Learning and Systems (MLSys)**, v. 3, p. 517-532, 2021. Disponível em: <https://arxiv.org/pdf/2010.11267>. Acesso em: 15 nov. 2025.

BONARDI, F. et al. Embedded Vision System for Real-Time Object Tracking Using an Asynchronous Transient Vision Sensor. In: **International Conference on Computer Vision Systems (ICVS)**, p. 125-135, 2015. Disponível em: <http://www.belbachir.info/PDF/dsp2006.pdf>. Acesso em: 15 nov. 2025.

BROWNING, B. et al. RoboCup Small Size League: Past, Present and Future. In: **RoboCup 2019: Robot World Cup XXIII**. Springer, Cham, p. 611-623, 2019.

CHEN, J.; RAN, X. Deep Learning with Edge Computing: A Review. **Proceedings of the IEEE**, v. 107, n. 8, p. 1655-1674, ago. 2019. Disponível em: <https://ieeexplore.ieee.org/document/8763885>. Acesso em: 15 nov. 2025.

ESPRESSIF SYSTEMS. ESP32-S3 Series Datasheet. Version 1.0. Shanghai: Espressif Systems, 2021. Disponível em: https://documentation.espressif.com/esp32-s3_datasheet_en.pdf. Acesso em: 15 nov. 2025.

KITANO, H. et al. RoboCup: The Robot World Cup Initiative. In: **Proceedings of the First International Conference on Autonomous Agents (AGENTS'97)**, p. 340-347, Marina del Rey, CA, USA, 1997. ACM Press.

LIN, J. et al. MCUNet: Tiny Deep Learning on IoT Devices. In: **Advances in Neural Information Processing Systems (NeurIPS)**, v. 33, p. 11711-11722, 2020.

MÜHLENBROCK, D. et al. Detecting and Tracking Robots in Real-Time Using RGB-D Data. In: **RoboCup 2018: Robot World Cup XXII**. Springer, Cham, p. 147-158, 2018.

WARDEN, P.; SITUNAYAKE, D. TinyML: Machine Learning with TensorFlow Lite

on Arduino and Ultra-Low-Power Microcontrollers. Sebastopol, CA: O'Reilly Media, 2019.

5 APÊNDICES

QUESTIONÁRIOS E/OU ENTREVISTAS